NVIDIA 30人联名论文，机器人看44000小时人类视频学会灵巧操作

原创 liuxjerry 具身纪元 2026年2月12日 20:59 上海

撰文：liuxjerry

编辑：Marilyn

前两天，NVIDIA联合UC Berkeley、UT Austin等一堆顶级机构，30个人联名发了一篇论文：

《DreamDojo: A Generalist Robot World Model from Large-Scale Human Videos》

NVIDIA 2026-2-9

DreamDojo: A Generalist Robot World Model from Large-Scale Human Videos

Shenyuan Gao[1,2†] William Liang[1,3†] Kaiyuan Zheng[1,4*] Ayaan Malik[1,5*] Seonghyeon Ye[1,6]
Sihyun Yu[6] Wei-Cheng Tseng[1,7] Yuzhu Dong[1] Kaichun Mo[1] Chen-Hsuan Lin[1] Qianli Ma[1]
Seungjun Nah[1] Loic Magne[1] Jiannan Xiang[8] Yuqi Xie[1] Ruijie Zheng[1] Dantong Niu[1,3]
You Liang Tan[1] K.R. Zentner[1] George Kurian[1] Suneel Indupuru[1] Pooya Jannaty[1] Jinwei Gu[1]
Jun Zhang[2] Jitendra Malik[3] Pieter Abbeel[3] Ming-Yu Liu[1] Yuke Zhu[1,9‡] Joel Jang[1‡] Linxi "Jim" Fan[1‡]
[1]NVIDIA [2]HKUST [3]UC Berkeley [4]UW [5]Stanford [6]KAIST [7]UofT [8]UCSD [9]UT Austin
[†]Co-First Authors [*]Core Contributors [‡]Project Leads
dreamdojo-world.github.io

图注：论文标题页

翻译成大白话就是：让机器人看人类的视频，学会想象这个世界会怎么运转。

30个作者。Jitendra Malik、Pieter Abbeel 、Ming-Yu Liu、Yuke Zhu，全是机器人和AI领域的大佬。Jim Fan也在上面，就是前几天写《预训练的第二种范式》和WAM的那位。 Jim Fan：具身智能的范式重心将从语言转向视觉

说实话，我读完之后，有一种很奇妙的感觉。

这篇论文做的事情，本质上就是在教机器人——

想象。

机器人的致命软肋：它不会想象

我们先来搞清楚一个概念，就是这篇论文里一直在说的世界模型到底是个啥。

你可以这么理解。

你现在闭上眼睛，想象你面前有一个苹果，你伸出手去拿它。

你不需要真的去拿，你的大脑就能模拟出整个过程：手伸出去，手指张开，包住苹果，抬起来。你甚至能想象到苹果的重量感，表面的光滑和微凉。

这个能力，就是你大脑里的世界模型。

它是你对这个物理世界的一套内在模拟器。你用它来预测行为的后果，在脑子里先演练一遍，然后再决定要不要真的去做。

现在的机器人，恰恰缺的就是这个。

它们可以看到世界（摄像头），可以在世界中行动（机械臂），但它们没法在脑子里想象一个动作执行以后，世界会变成什么样子。

你让一个机器人去抓一个从来没见过的杯子，它会很懵。

因为它没有如果我这样抓、杯子会怎样的想象力。

为什么现有的教机器人方法走不通

你可能会说，那让机器人多练不就完了？给它大量的数据，让它反复操作，总会学会的吧。

道理是这么个道理，但问题是——

机器人数据，太少了，也太贵了。

你想训练一个能在厨房里干活的机器人，你得真的搞一台机器人，放在真的厨房里，让它真的去抓碗、拿筷子、开抽屉。

每一次操作，都需要人类遥操作或者精心设计的程序来执行和记录。一个小时的高质量机器人数据，背后可能是几万块钱的设备成本和几天的人工时间。

而且，你在厨房A里收集的数据，换到厨房B可能就不好使了，因为灯光不一样、桌子高度不一样、碗的材质不一样。

这就导致了一个恶性循环： **数据少 → 模型笨 → 泛化差 → 需要更多数据 → 数据还是少** 。

DreamDojo的天才想法：看人不就得了？

DreamDojo的核心洞见，其实朴素到令人发指。

他们说：机器人数据不够，那——

我们看人类的视频不就得了？

你想啊，人类每天都在用手跟世界互动。做饭、收拾房间、修东西、叠衣服、喝咖啡。

这些互动的视频，在互联网上，简直是汪洋大海，取之不尽用之不竭。

而且，最关键的一点：不管你是人类的手在抓杯子，还是机器人的爪子在抓杯子，**杯子被抓起来的物理过程是一样的**。

重力不会因为你是机器人就变了，摩擦力不会因为你是铁皮手就不存在了。

物理规律，是人类和机器人共享的。

所以，DreamDojo团队做了一件疯狂的事。

他们收集了 **44,000个小时** 的第一人称人类视频。

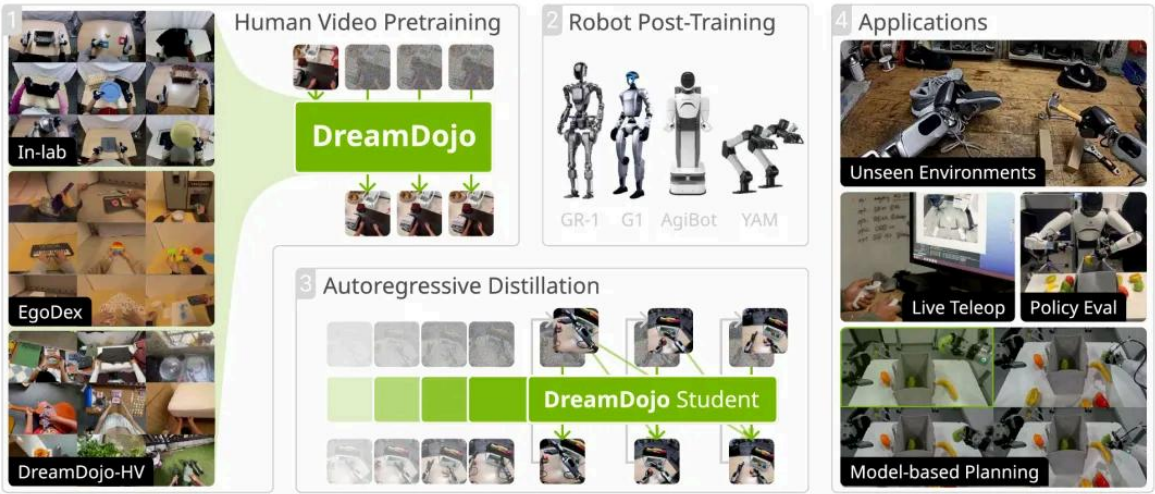

图注：DreamDojo整体架构图

四万四千个小时是什么概念？

如果你从现在开始，一天24小时不睡觉不吃饭不停地看，你需要连续看 **整整5年**。

这也是目前为止，用于世界模型预训练的 **最大视频数据集**，比之前最大的数据集多出了 **15倍的时长**、**96倍的技能种类**、**2000倍的场景数量**。

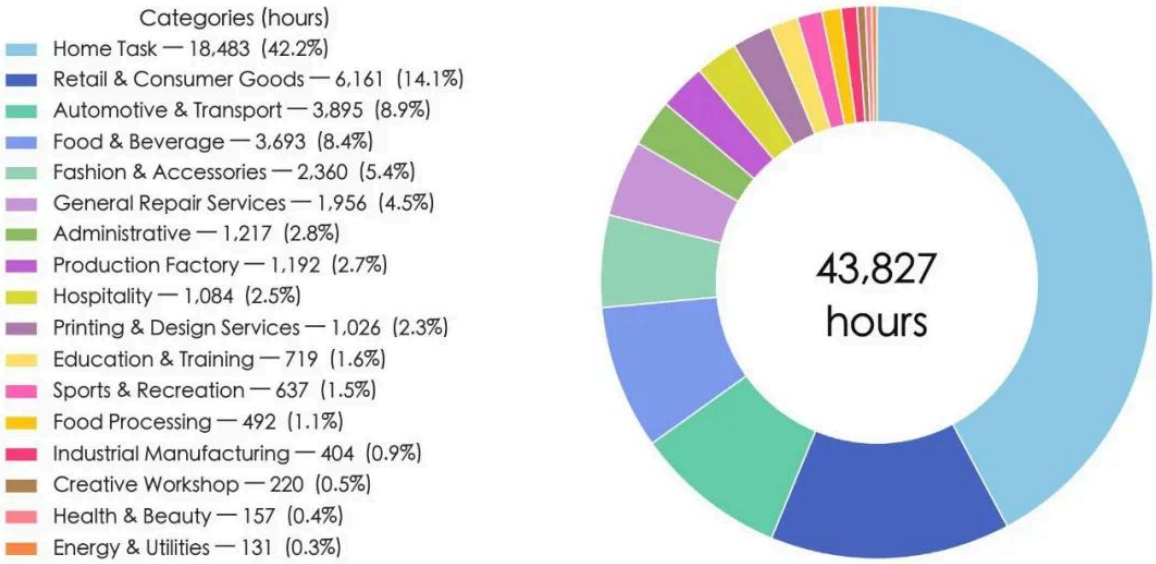

图注：DreamDojo-HV数据集分布分析

这些视频涵盖了你能想到的几乎所有日常场景——家庭做家务（占了42%）、零售与消费品（14%）、汽车与交通（9%）、餐饮（8%）、还有工业制造、教育培训、体育运动等等。

图注：数据集子任务和技能分布

里面的操作技能也是五花八门：pick（抓取）、place（放置）、fold（折叠）、wipe（擦拭）、move（移动）、push（推）、scrub（刷洗）、pour（倒）。。。涉及的物体更是多达**43,237种**，从衬衫、架子、碗、纸张到各种工具。

最难的问题：人的手和机器人的手不一样啊

好了，数据有了，但最大的问题来了。

你看了44000小时的人类视频，看的都是人的手在操作物品。但机器人的手长得跟人完全不一样啊？有的是双指夹持器，有的是灵巧五指手，有的压根就是一个吸盘。

更要命的是，人类视频里没有动作标签。

什么意思呢？

就好比你看一个做饭视频，你能看到厨师在切菜，但你不知道他的手指关节具体弯了多少度、手腕转了多少角度、施加了多少力。

这些信息在视频里是看不到的。

那怎么办？

DreamDojo想了一个非常聪明的方案：**潜在动作（Latent Actions）**。

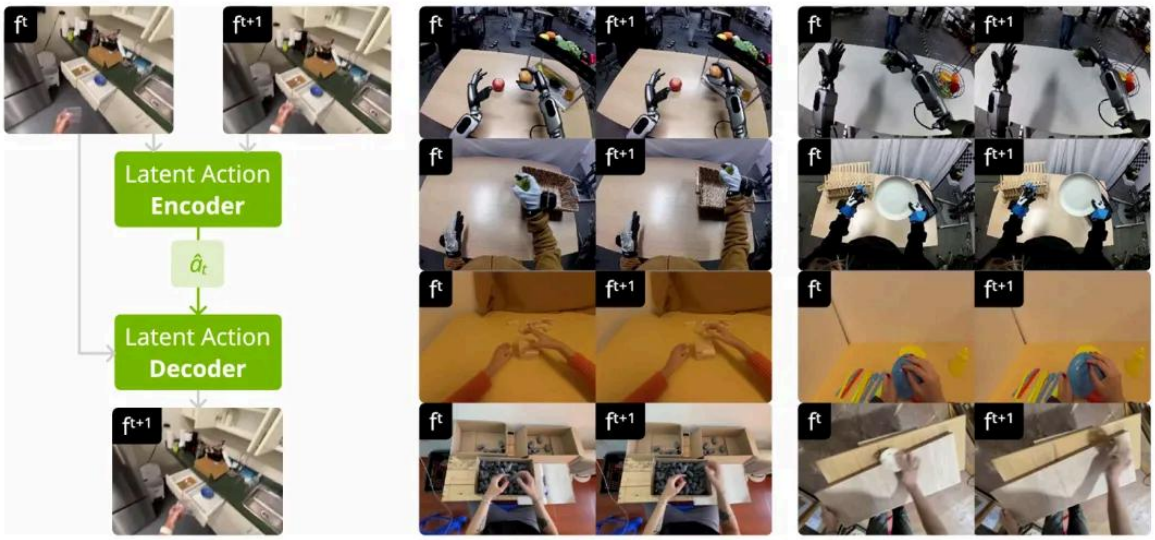

图注：潜在动作模型架构

说人话就是：他们不去识别人手的具体动作，而是让AI自己去感受两帧画面之间到底发生了什么变化。

你给它看两张连续的照片——第一张苹果在桌上，第二张苹果在手里。

AI不需要知道手指弯曲了47度、手腕旋转了23度这种具体信息。它只需要学到一个抽象的动作表示：**从状态A到状态B，发生了某种操作**。

这个操作被压缩成一个32维的小向量，就是所谓的潜在动作。

最妙的是，这种表示方式是**跨身体的**。

不管是人手抓苹果、机器爪子夹苹果、还是机器人五指手拿苹果，只要物理效果相似，它们在这个潜在动作空间里的表示就是接近的。

人类的动作经验，就这样被翻译成了机器人能理解的语言。

三步走：从看视频到能干活

DreamDojo的整个训练流程，大致可以分成三步。

第一步：看人类视频，学习物理常识。

把44000小时的人类视频一股脑灌给模型，同时用潜在动作作为条件信号。模型的任务是：给你看一帧画面和一个动作，你来预测下一帧画面会长什么样。

通过海量的训练，模型逐渐学会了一整套物理直觉：东西会因为重力掉下来、被推的物体会滑动、液体会流动、布料会皱褶。。。

第二步：适配目标机器人。

人类视频看完了，但机器人毕竟不是人。所以需要在少量的真实机器人数据上做微调。

但因为有了第一步的强大预训练，这一步需要的数据量非常少。模型已经知道了物理世界的基本规则，现在只需要学习我这个特定的机器人身体，应该怎么跟这些规则对接。

就像一个人如果理解了物理规律，换一双筷子他也能很快适应，不需要从头学起。

第三步：蒸馏加速，让它能实时跑起来。

原始模型虽然厉害，但跑起来太慢了，每生成一帧画面需要几秒钟。做不到实时。

所以他们又搞了一个蒸馏流程，把大模型的能力压缩进一个小而快的学生模型里。

蒸馏后的模型，速度飙到了 **10.81 FPS** （每秒10.81帧），640×480分辨率，在单张NVIDIA RTX 5090显卡上就能实时运行。

而且！蒸馏还带来了一个意外的好处——上下文一致性变好了。原始模型生成长视频时容易跑偏，蒸馏后的模型因为采用了自回归架构，反而更能保持前后一致。

效果到底怎么样？

这部分的数据，说实话，是真的炸。

先看 **物理建模能力** 。

和直接用Cosmos-Predict2.5（没有人类视频预训练的基线模型）相比，DreamDojo在所有评测集上都有显著提升。特别是在从来没见过的物体和场景上，DreamDojo依然能给出合理的物理模拟结果。

这意味着它真的学到了 **通用的物理常识** ，而不是死记硬背了训练数据。

再看 **人类偏好评估** 。

他们请了12个志愿者，让他们对比DreamDojo和基线模型生成的视频，从物理正确性和动作跟随性两个维度打分。

对比	物理正确性胜率	动作跟随胜率
DreamDojo-2B vs Cosmos-Predict2.5	**62.50%**	**63.45%**
DreamDojo-14B vs Cosmos-Predict2.5	**73.50%**	**72.55%**
DreamDojo-14B vs DreamDojo-2B	**72.50%**	**65.53%**

14B的大模型对基线，物理正确性赢了 **73.5%** ，接近四分之三的比例。人都觉得DreamDojo生成的视频更真实。

最让我惊讶的，是 **策略评估** 的实验。

他们用DreamDojo来评估机器人抓水果装袋的策略好不好，然后把DreamDojo给出的成功率和真实世界的成功率做对比。

结果， **Pearson相关系数达到了0.995** 。

0.995是什么概念？

就是DreamDojo觉得好的策略，在真实世界里也好；DreamDojo觉得差的策略，在真实世界里也差。两者几乎完全一致。

这意味着什么？

意味着你以后评测机器人策略好不好，可能 **不需要真的跑真实机器人了** 。直接在DreamDojo的梦境里跑一遍就行了。

省钱、省时间、省设备、还不会摔坏机器人。

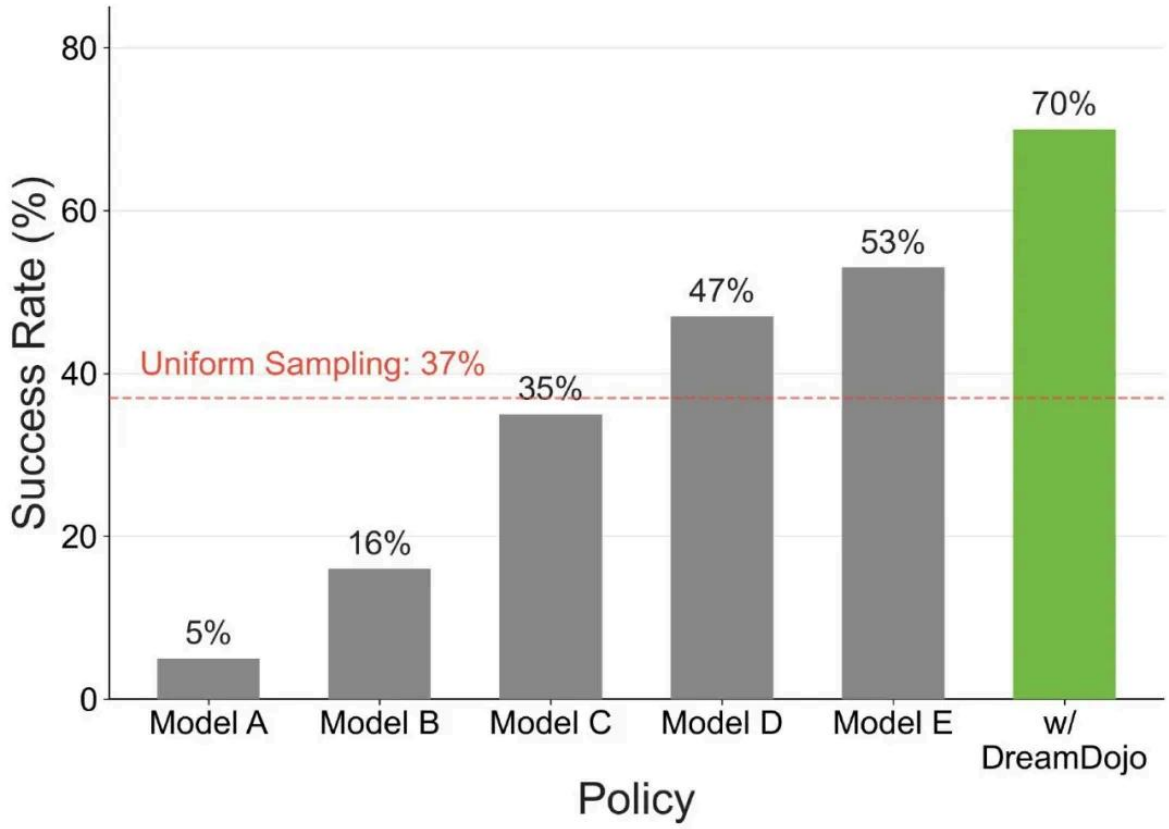

图注：下游应用效果展示

而且，基于模型的规划（Model-based Planning）实验也很强。用DreamDojo来辅助策略选择，成功率直接提升了 **17%** ，相比随机选择策略提升了 **近2倍** 。

实时遥操作：你可以用VR手柄操控虚拟机器人

还有一个特别酷的应用。

他们把蒸馏后的DreamDojo部署在一台装了RTX 5090的电脑上，然后连接一个PICO VR手柄。

你戴上VR设备，动动手，屏幕上的虚拟Unitree G1人形机器人就会实时跟着你动。

图注：实时遥操作演示

不是动画，不是渲染。

是DreamDojo在实时想象你的动作会让机器人和环境发生什么变化，然后把想象出来的画面实时呈现给你。

10.81 FPS，实时速度。

这意味着，未来你可以先在梦境里让机器人练习，确认没问题了，再让真实机器人去执行。

虚拟试错，真实部署。

往大了说：机器人的睡眠学习时代来了

读完这篇论文，我一直在想一个问题。

人类婴儿是怎么学会抓东西的？

他不是看了一本《如何抓取物体》的教材。

他是看了无数次妈妈的手在面前晃来晃去、看了无数次奶瓶从桌上被拿起又放下、看了无数次自己的手随机挥舞偶尔碰到了什么东西。

然后在某一天，他伸出手，稳稳地抓住了面前的积木。

他的大脑，通过观察别人、感受物理世界，自然而然地构建起了一个关于抓取的世界模型。

DreamDojo做的事，和这个过程惊人地相似。

它不是直接学习怎么抓，而是先通过观看44000小时的人类操作视频，构建起一个关于物理世界如何运转的内在模型。

它先学会了想象，然后才学会了干活。

这条路，可能真的就是通向通用机器人的正确道路。

当然，论文也很诚实地说了局限性：对于一些不常见的动作（比如拍打、快速挥手），模型表现还不够好。策略评估时，DreamDojo给出的成功率有时候反而比真实世界更高，说明它还不擅长精确模拟失败的场景。

但这些都是可以改进的细节。

大方向已经被验证了——**观看人类，理解物理，想象未来，指导行动**。

也许有一天，每一个机器人出厂之前，都要先做一场漫长的梦。

在梦里，它看过了无数人类的手如何轻柔地拿起一个鸡蛋、如何小心翼翼地叠好一件衬衫、如何灵巧地拧开一个瓶盖。

等它醒来的时候，它已经懂得了这个世界的温柔和分寸。

DreamDojo。

梦之道场。

名字起得真好。

> 论文：
> https://arxiv.org/abs/2602.06949
> 项目主页：
> https://dreamdojo-world.github.io/

欢迎关注我们

具身纪元
见证具身浪潮，书写智能新纪元
61篇原创内容

公众号

欢迎与我们交流，加好友请注明来意，xingxing-lxy：）

阅读 2154

留言 1

写留言

清梦 浙江 12小时前
WAM看上去很有研究意义，要变新热点了